
ANÁLISIS COMPARATIVO DE COMUNIDADES EN ETHEREUM: DE POW A POS

A PREPRINT

Ignacio Argel
FIUBA
iargel@fi.uba.ar

Manuel V. Battan
FIUBA
mvbattan@fi.uba.ar

Lucas Bilo
FIUBA
lbilo@fi.uba.ar

Nahuel H. Spiguelman
FIUBA
nspiguelman@fi.uba.ar

May 24, 2024

ABSTRACT

El cambio de Proof of Work a Proof of Stake en la blockchain descentralizada de Ethereum tiene un impacto directo en la función desempeñada por los mineros, ya que son reemplazados por Stakers como nuevos validadores de la red. La disparidad en las dinámicas de este nuevo protocolo plantea interrogantes sobre si ha ocasionado modificaciones en el comportamiento de los usuarios que operan en él, ya sean stakers o participantes frecuentes de la red. Las investigaciones previas en Ethereum han priorizado aspectos técnicos, dejando un vacío en el análisis de interacciones entre cuentas y la formación de comunidades. Esto es especialmente notorio en la ausencia de estudios que aborden cómo el comportamiento de usuarios y comunidades ha cambiado con la migración de PoW a PoS. Para este análisis utilizaremos un modelo cuya finalidad es crear embeddings de nodos que representen, de una manera inteligente, las relaciones entre addresses en la red. A su vez, este modelo es superador en términos de limitaciones computacionales y de utilización de features, que algoritmos tradicionales para analizar grafos no tienen en cuenta por defecto.

1 Introducción

La blockchain Ethereum ha sido una de las innovaciones más significativas en el mundo de la tecnología financiera en la última década. Desde su lanzamiento en 2015, Ethereum ha operado bajo un protocolo de consenso conocido como Proof of Work (PoW), el cual ha demostrado ser robusto y confiable en la validación de transacciones y la seguridad de la red, pero presentando problemas como el alto consumo de energía y la centralización de la minería de bloques. Debido a estos problemas, Ethereum ha migrado hacia el protocolo de consenso conocido como Proof of Stake (PoS), el cual incluye varios cambios en la manera de garantizar la integridad durante las transacciones, mejorando la escalabilidad y la eficiencia de la red. Algunas preguntas significativas que surgen a partir del cambio de paradigma: ¿Existe un cambio en el comportamiento de los usuarios debido a esta transición? ¿Cuáles son los comportamientos invariantes o que siguen siendo vigentes después del cambio? ¿Cómo variaron las relaciones entre usuarios y comunidades?

El presente proyecto tiene como objetivo principal contestar estas preguntas. A través de un análisis exhaustivo, buscamos proporcionar una visión clara de los patrones de comportamiento de quienes operan sobre la red de Ethereum en sus dos protocolos de consenso principales, PoW y PoS. Al hacerlo, esperamos contribuir a la comprensión de las implicaciones de esta transición para la comunidad Blockchain, los desarrolladores y los usuarios de Ethereum.

1.1 Investigación

1.1.1 Artículos relacionados

Ethereum - Yellow paper

Para establecer una base sólida y comprender exhaustivamente los aspectos fundamentales de Ethereum, incluyendo su red y el proceso de transacciones, optamos por examinar el documento original de Ethereum.

ETHEREUM: A SECURE DECENTRALISED GENERALISED TRANSACTION LEDGER

El documento proporciona una riqueza de información crucial, detallando temas fundamentales como los campos de las transacciones, la naturaleza de los bloques, el protocolo de consenso (entonces basado en Prueba de Trabajo, PoW), y otros aspectos de suma importancia.

Artículos muy relacionados

Como una sugerencia inicial y como punto de partida para abordar el tema, se nos recomendó revisar el siguiente documento académico acerca de la detección de comunidades ilícitas en la red de Bitcoin. Aunque en sus conclusiones se menciona la falta de resultados satisfactorios, el documento proporciona una definición de comunidades, propone diversas técnicas y evalúa el rendimiento mediante métricas específicas. Una idea inicial era encarar el trabajo sobre esto mismo, pero en ethereum, relacionándolo con cambio de protocolo de consenso.

Illegal Community Detection in Bitcoin Transaction Networks

Luego de eso, buscamos artículos recientes que recopilaran algo de la situación actual científica respecto a la red de ethereum y su análisis como un grafo. Este paper nos dio un punto de partida en lo que respecta a la diversidad de tipos de cuentas y tipos de transacciones dentro de la red. Viendo esto, nos dimos cuenta que debíamos limitar el scope del grafo, ya que los distintos tipos de cuenta y transacciones se comportan de una manera muy diferente. Debido a esto, decidimos focalizarnos en las transacciones que tienen un value, transaccionado el token Ether.

Graph Analysis of the Ethereum Blockchain Data: A Survey of Datasets, Methods, and Future Work

El último paper y estrechamente vinculado que hemos identificado se enfoca en la identificación de comunidades dentro de redes sociales. En este contexto, se sugiere la aplicación de la matriz de covarianza de salida de baja dimensionalidad sobre los datos de transacciones, seguido por la extracción de los K autovectores. Posteriormente, se emplea el algoritmo de K-means para la partición de los nodos en K grupos distintos. Es interesante que la conclusión y las pruebas definitivas, se hacen sobre un grafo de tamaño reducido.

Community Detection in Blockchain Social Networks

Una hipótesis surgida de estos análisis es si es la mejor opción buscar comunidades utilizando K-means, ya que el algoritmo obligatoriamente separa en K clusters, sin dejar a nadie fuera de una comunidad.

1.1.2 Papers complementarios

Si bien estos papers no fueron foco principal de nuestra investigación, los revisamos de forma rápida viendo si encontrábamos insights inspiradores o novedosos.

Este paper es uno de los primeros trabajos científicos que definen una comunidad, lo que la hace una lectura muy interesante.

Community structure in social and biological networks

En el siguiente se presenta el primer estudio empírico a gran escala sobre el uso de Inline Assembly en contratos inteligentes de Ethereum, analizando millones de contratos desde diversas perspectivas técnicas. Proporciona nuevas observaciones y percepciones valiosas para el desarrollo de contratos inteligentes y la evolución de Solidity y sus compiladores.

Large-Scale Empirical Study of Inline Assembly on 7.6 Million Ethereum Smart Contracts

*****INSERTE SUS PAPERS LEIDOS ACA*****

2 Fuente de datos

La primera complicación con la que nos enfrentamos fue la búsqueda de una fuente de datos íntegra, sin limitaciones significativas en términos de cantidad y accesibilidad. Inicialmente, exploramos la posibilidad de utilizar APIs con el propósito de obtener muestras extensas y almacenarlas. Sin embargo, la restricción en el número de solicitudes permitidas, junto con la complejidad inherente de realizar una cantidad considerable de peticiones y la gestión de almacenamiento para tal volumen de datos, nos llevó a desechar esta estrategia.

Ejemplos de APIs revisadas (entre otras):

- Blockchain Data
- Etherscan

Posteriormente, consideramos la posibilidad de replicar un nodo. Contábamos con diversas alternativas, si bien replicar un nodo plantea ciertas dificultades técnicas y de almacenamiento. Las alternativas que evaluamos fueron las siguientes:

- **Nodo completo (Full node):** Este tipo de nodo conserva y administra una réplica integral de la cadena de bloques de Ethereum, aunque con ciertos recortes (pruning). Esto abarca todas las transacciones efectuadas en la red, así como el estado actualizado de todas las cuentas y contratos inteligentes hasta un punto en el tiempo determinado. La implementación de este tipo de nodo requiere una capacidad de almacenamiento de aproximadamente 1.5 TB.
- **Nodo de archivo (Archive node):** Se trata de una categoría de nodo que preserva todo el historial completo de la cadena de bloques desde su bloque inicial hasta el más reciente. Esto incluye todas las transacciones, contratos inteligentes, eventos y estados históricos de todas las cuentas. La variante más ligera de este tipo de nodo requiere alrededor de 10 TB de almacenamiento hasta mayo de 2022.

Sin embargo, esta opción fue desecheda debido a la limitación de recursos de almacenamiento disponibles y a la falta de necesidad de poseer los datos en su totalidad.

Por último, hemos identificado un dataset en BigQuery que, aunque no está sincronizado en tiempo real, se actualiza diariamente. Las consultas realizadas en este conjunto de datos son gratuitas y, para propósitos prácticos, su límite es inalcanzable. Los campos disponibles en este conjunto de datos son los siguientes:

- block_hash
- block_number
- block_timestamp
- transaction_hash

- transaction_index
- nonce
- from_address
- to_address
- value
- value_lossless
- gas
- gas_price
- max_fee_per_gas
- max_priority_fee_per_gas
- transaction_type
- chain_id
- r
- s
- v
- y_parity

Con acceso a este conjunto de datos y la capacidad de realizar consultas sobre cualquier ventana temporal desde el inicio de la cadena hasta el día anterior al actual, tenemos la información necesaria para nuestros análisis.

3 Análisis exploratorio

3.1 Introducción

Una vez conseguidos los datos, debíamos empezar a analizar los mismos, con el fin de conocer mejor los datos, su evolución y en base a eso tomar la decisión de que subset de datos pre y post cambio de protocolo de consenso vamos a elegir para la comparación final.

Para esto, decidimos plantear una serie de métricas